

Resumen Estructurado — Introducción a LLMs e Integración con APIs

Documento optimizado para chunking y uso en sistemas RAG (Retrieval-Augmented Generation). El contenido se ha reorganizado en bloques conceptuales claros y autocontenidos.

1. IA Generativa y LLMs

La IA Generativa es una rama de la inteligencia artificial capaz de crear contenido original como texto, imágenes, código o audio. A diferencia de la IA tradicional, no solo analiza datos: genera nueva información a partir de patrones aprendidos durante el entrenamiento.

- Los LLMs (Large Language Models) están basados en arquitecturas Transformer.
- Aprenden relaciones estadísticas entre palabras y tokens.
- Predicen el siguiente token de una secuencia para generar texto coherente.
- Son entrenados con enormes volúmenes de datos textuales.

2. Evolución de los modelos NLP

Antes de los Transformers, los modelos más utilizados eran RNN, LSTM y GRU. Estos modelos procesaban información secuencialmente, lo que dificultaba el paralelismo y la captura de dependencias largas.

Año	Hito
2013	Word2Vec y embeddings semánticos
2015	Seq2Seq con atención
2017	Transformer — Attention Is All You Need
2018-2020	BERT, GPT-2 y T5
2020-2023	GPT-3, Codex, PaLM, LLaMA

3. Arquitectura Transformer

El Transformer revolucionó el NLP al eliminar recurrencias y utilizar mecanismos de atención. Esto permitió entrenar modelos mucho más grandes y eficientes utilizando GPUs.

- Procesamiento paralelo de secuencias.
- Uso de embeddings y codificación posicional.
- Capas repetidas de atención y redes feed-forward.
- Separación conceptual entre Encoder y Decoder.
- Escalabilidad a miles de millones de parámetros.

4. Mecanismo de Atención

La atención permite al modelo decidir qué partes del contexto son más relevantes en cada paso. El mecanismo principal utiliza tres vectores: Query (Q), Key (K) y Value (V).

- Calcula similitudes entre tokens.
- Asigna pesos mediante softmax.
- Permite capturar dependencias largas.
- La multi-head attention analiza distintas relaciones en paralelo.

5. Tokenización y Embeddings

Los textos deben convertirse en representaciones matemáticas antes de ser procesados por un modelo. La tokenización divide el texto en fragmentos y los embeddings transforman cada token en vectores densos que capturan significado semántico.

Estos embeddings permiten que palabras similares tengan representaciones cercanas en el espacio vectorial, facilitando tareas como búsqueda semántica y recuperación en sistemas RAG.

6. Funcionamiento de los LLMs

Los LLMs generan texto token a token. En cada paso calculan la probabilidad del siguiente token en función del contexto previo.

- Greedy Decoding: selecciona siempre el token más probable.
- Top-k Sampling: elige entre los k tokens más probables.
- Top-p Sampling: selecciona tokens hasta alcanzar un umbral de probabilidad.
- Temperatura: controla creatividad y aleatoriedad.

7. Capacidades y Aplicaciones

Los LLMs pueden generar texto, resumir documentos, traducir idiomas, escribir código, responder preguntas y mantener conversaciones complejas.

- Chatbots y atención al cliente.
- Generación automática de contenido.
- Asistencia en programación.
- Análisis legal y documental.
- Educación y tutores virtuales.

8. Limitaciones y Alucinaciones

Los modelos no comprenden realmente el significado de las respuestas; únicamente predicen patrones estadísticos. Esto puede provocar alucinaciones: información falsa presentada como correcta.

- Invención de datos o fechas incorrectas.
- Sesgos heredados del corpus de entrenamiento.
- Falta de sentido común real.
- Conocimiento limitado o desactualizado.

9. Buenas prácticas para sistemas RAG

Los sistemas RAG combinan recuperación de información y generación mediante LLMs. Para obtener buenos resultados, el contenido debe estar bien estructurado y chunked correctamente.

- Crear chunks autocontenidos y coherentes semánticamente.
- Mantener títulos y subtítulos claros.
- Evitar mezclar demasiados conceptos en un mismo fragmento.
- Usar embeddings para búsqueda vectorial.
- Incluir contexto suficiente sin exceder el tamaño del chunk.

10. Integración mediante APIs

Los modelos pueden integrarse en aplicaciones mediante APIs. El acceso suele realizarse utilizando claves API y peticiones HTTP.

- Las API Keys autentican el acceso a los modelos.
- Las claves deben almacenarse en variables de entorno.
- Nunca deben compartirse en repositorios públicos.
- El método habitual es Authorization: Bearer TOKEN.

11. Modelos relevantes en la actualidad

Entre los modelos más utilizados destacan GPT-4, Claude, Gemini, LLaMA y Mistral. Algunos son propietarios y otros open source, variando en coste, velocidad y capacidad multimodal.

Conclusión: Los LLMs y la arquitectura Transformer han transformado el NLP moderno. Comprender tokenización, embeddings, atención, generación y chunking es clave para construir agentes con RAG robustos, escalables y útiles en entornos reales.